

Towards Semantic Annotation Supported by Dependency Linguistics and ILP

Jan Dědek

Department of Software Engineering, Faculty of Mathematics and Physics,
Charles University in Prague, Czech Republic

Uživatelsko-webový seminář, 6. 10. 2010, MFF UK, Praha

Outline

1

Introduction

- Our Information Extraction System
- Linguistics we have used
- Domain of fire-department articles

2

Our Information Extraction Method

- Manually created rules
- Learning of rules
- Evaluation


3

Conclusion

Introduction to Presented Work

- Extraction of semantic information from **texts**.
 - In Czech language.
 - Coming from web pages.
- Using of Semantic Web **ontologies**.
 - RDF, OWL
- Exploiting of linguistic tools.
 - Mainly from the **Prague Dependency Treebank** project.
 - Experiments with the Czech WordNet.
- **Rule based** extraction method.
 - Extraction rules \approx **tree queries**
 - ILP learning of extraction rules


Schema of the extraction process



- 1 Extraction of text
 - Using **RSS feed** to download pages.
 - **Regular expression** to extract text.
- 2 Linguistic annotation
 - Using **chain** of 6 linguistic tools (see on next slides).
- 3 Data extraction
 - Exploitation of linguistic trees.
 - Using **extraction rules**.
- 4 Semantic representation of data
 - Ontology needed.
 - Semantic interpretation of rules.
 - Far from finished in current state.

Linguistics we have used

Layers of linguistic annotation in PDT



- Tectogrammatical layer
- Analytical layer
- Morphological layer
- PDT 2.0 on-line:

<http://ufal.mff.cuni.cz/pdt2.0/>

Sentence:

Byl by šel dolesa.


He-was would went toforest.

Tools for machine linguistic annotation

- ① Segmentation and tokenization
 - ② Morphological analysis
 - ③ Morphological tagging
 - ④ McDonald's Maximum Spanning Tree parser
 - Czech adaptation
 - ⑤ Analytical function assignment
 - ⑥ Tectogrammatical analysis
 - Developed by Václav Klimeš
- Available within the **TectoMT**¹ project

¹<http://ufal.mff.cuni.cz/tectomt/>

Example of tectogrammatical tree



- Lemmas
- Functors
- Semantic parts of speech

Sentence:

Ve zdemolovaném trabantu na místě zemřeli dva muži – 82letý senior a další muž, jehož totožnost zjišťují policisté.

Two men died on the spot in demolished trabant – ...

Example of the web-page with a report of a fire department




Ministerstvo vnitra
[domů](#) [navigace](#) [vyhledávání](#) [změna vzhledu](#)

Zpravodajství
Informace z resortu o tom, co se stalo, co se děje i co se připravuje



HZS Jihomoravského kraje
Zubatého 1, 614 00 Brno, telefon 950 630 111,
<http://www.firebrno.cz>
Zpravodajství v roce 2006

15.05.2007
V trabantu zemřeli dva lidé
K tragické nehodě dnes odpoledne hasiči vyjžděli na silnici z obce Česká do Kuřimi na Brněnsku.

Nehoda byla operačním střediskem HZS ohlášena ve 13.13 hodin a na místě zasahovala jednotka profesionálních hasičů ze stanice v Tišnově. Jednalo se o čelní srážku autobusu Karosa s vozidlem Trabant 601. Podle dostupných informací trabant jedoucí ve z Brna do Kuřimi zřejmě vyjel do protisměru, kde narazil do linkového autobusu dopravní společnosti ze Žďáru nad Sázavou. Ve zdemolovaném trabantu na místě zemřeli dva muži – 82letý senior a další muž, jehož totožnost zjišťují policisté.

Hasiči udělali na vozidle protipožární opatření a po vyšetření a zadokumentování nehody dopravní policií vrak trabantu zaklesnutý pod autobusem pomocí lana odtrhli. Po odstranění střechy trabantu pak z kabiny vyprostili těla obou mužů. Obě vozidla – trabant i autobus, pak postupně odstranili na kraj vozovky a uvolnili tak jeden jízdní pruh. Únik provozních kapalin nebyl zjištěn. Po 16. hodině pomohli vrak trabantu naložit k odtahu a asistovali při odtažení autobusu. Po úklidu vozovky krátce před 16.30 hod. místo nehody předali policistům a ukončili zásah.






Odkazy

skrz menu

Hasiči

- Generální ředitelství
- hl. m. Praha
- Jihočeský kraj
- Jihomoravský kraj
- Karlovarský kraj
- Královéhradecký kraj
- Liberecký kraj
- Moravskoslezský kraj
- Olomoucký kraj
- Pardubický kraj
- Píseňský kraj
- Středočeský kraj
- Ústecký kraj
- kraj Vysočina
- Zlínský kraj



V této rubrice Zpravodajství

- Aktualizace stránek
- Archiv zpravodajství
- Bleskové zpravodajství
- RSS
- Boj proti korupci
- Digitalní televize
- Hasiči
- Hlavní zprávy
- Ministerstvo
- Od dopisovatelů (neoficiální)
- Policie
- Regiony
- Servis nejen pro novináře
- Schengenská spolupráce
- WebEditorial

Na našem serveru v jiných rubrikách

- Aktuality Národního archivu

Domain of our experiments

- Fire-department articles
- Published by The Ministry of Interior of the Czech Republic²
- Processed more than 800 articles from different regions of Czech Republic
- 1.2 MB of textual data
- Linguistic tools produced 10 MB of annotations, run time 3.5 hours
- Extracting information about injured and killed people
- 470 matches of the extraction rule, 200 numeric values of quantity (described later)

²<http://www.mvcr.cz/rss/regionhzs.html>

Domain of fire-department articles

Example of processed text

fire

3 amateur units

started at

2.13

finished at 4:03

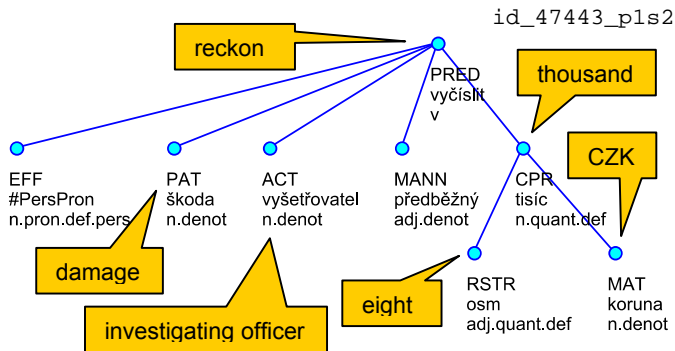
damage 8 000 CZK

id_47443

Požár byl operace na středně velkou požár ohlášen dnes ve 2.13 hodin, na místo vyjeli profesionální hasiči ze stanice v Židlochovicích a dobrovolní hasiči z Židlochovic, Žabčic a Přisnotic, Oheň, troinstalaci u chladicího boxu, hasiči dostali pod kontrolu ve 2.32 hodin a uhasili tři minuty po třetí hodině. Příčinou vzniku požáru byla technická závada, škodu vyšetřovatel předběžně vyčíslil na osm tisíc korun.

- Information to be extracted is decorated.
- See the last sentence on the next slide.

Example of a linguistic tree



..., škodu vyšetřovatel předběžně vyčísil na osm tisíc korun.

..., investigating officer preliminarily reckoned the damage to be 8 000 CZK.

- Our IE method uses **tree queries** (tree patterns)

1 Introduction

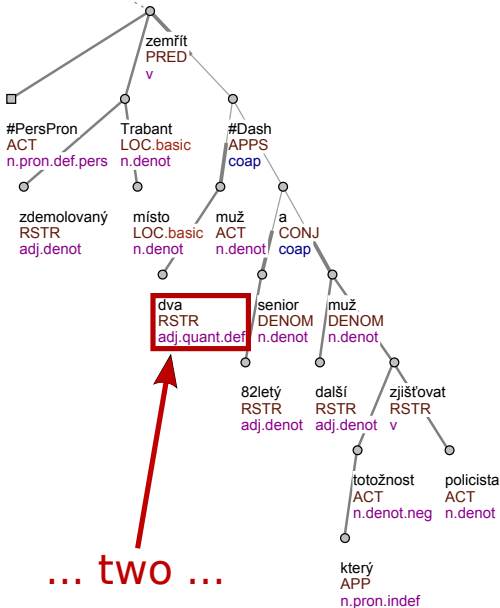
- Our Information Extraction System
- Linguistics we have used
- Domain of fire-department articles

2 Our Information Extraction Method

- Manually created rules
- Learning of rules
- Evaluation

3 Conclusion

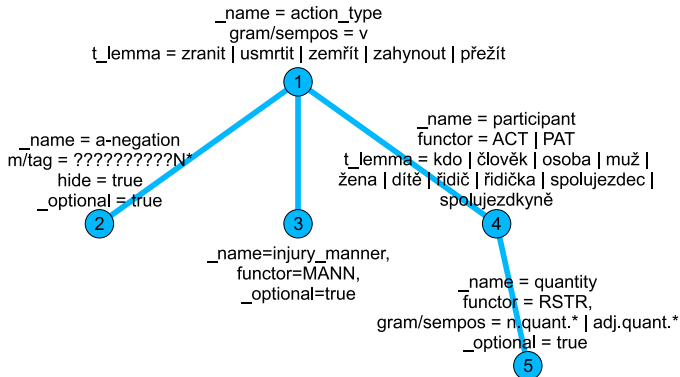
T-jihomoravsky49640.txt-001-p1s4
root



- How to extract the information about **two dead** people?

... two ...

Extraction rules – Netgraph queries




- Tree patterns on **shape** and **nodes** (on node attributes).
- Evaluation gives **actual matches** of particular nodes.
- **Names** of nodes allow use of references.

Manually created rules

Raw data extraction output

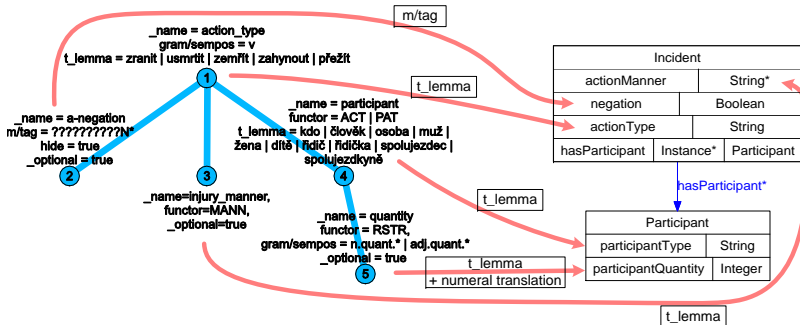
```
<QueryMatches>
  <Match root_id="T-vysocina63466.txt-001-pls4" match_string="2:0,7:3,8:4,11:2">
    <Sentence>
      Při požáru byla jedna osoba lehce zraněna - jednalo se
      o majitele domu, který si vykloubil rameno.
    </Sentence>
    <Data>
      <Value variable_name="action_type" attribute_name="t_lemma">zranit</Value>
      <Value variable_name="injury_manner" attribute_name="t_lemma">lehký</Value>
      <Value variable_name="participant" attribute_name="t_lemma">osoba</Value>
      <Value variable_name="quantity" attribute_name="t_lemma">jeden</Value>
    </Data>
  </Match>
  <Match root_id="T-jihomoravsky49640.txt-001-pls4" match_string="1:0,13:3,14:4">
    <Sentence>
      Ve zdemolovaném trabantu na místě zemřeli dva muži - 82letý senior
      a další muž, jehož totožnost zjišťují policisté.
    </Sentence>
    <Data>
      <Value variable_name="action_type" attribute_name="t_lemma">zemřít</Value>
      <Value variable_name="participant" attribute_name="t_lemma">muž</Value>
      <Value variable_name="quantity" attribute_name="t_lemma">dva</Value>
    </Data>
  </Match>
  <Match root_id="T-jihomoravsky49736.txt-001-p4s3" match_string="1:0,3:3,7:1">
    <Sentence>Ctyřiatřicetiletý řidič nebyl zraněn.</Sentence>
    <Data>
      <Value variable_name="action_type" attribute_name="t_lemma">zranit</Value>
      <Value variable_name="a-negation" attribute_name="m/tag">VpYS---XRⓃA---
      </Value>
      <Value variable_name="participant" attribute_name="t_lemma">řidič</Value>
    </Data>
  </Match>
</QueryMatches>
```



SELECT **action_type.t_lemma**, **a-negation.mtag**, **injury_manner.t_lemma**,
participant.t_lemma, **quantity.t_lemma** **FROM** ****extraction rule****

Manually created rules

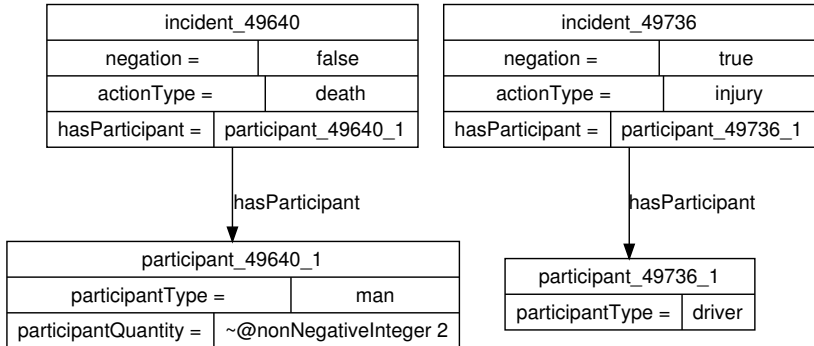
Semantic interpretation of extraction rules



- Determines how particular values of attributes are used.
- Gives semantics to extraction rule.
- Gives semantics to extracted data.

Manually created rules

Semantic data output



- Two instances of two ontology classes.

Manually created rules

The experimental ontology

Incident		
actionManner	String*	
negation	Boolean	
actionType	String	
hasParticipant	Instance*	Participant

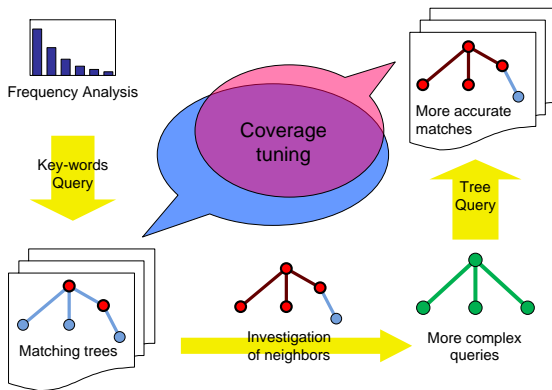
↓
hasParticipant*

Participant	
participantType	String
participantQuantity	Integer

- Two **classes**
 - Incident and Participant
- One **object property** relation
 - hasParticipant
- Five **datatype property** relations
 - actionManner
(light or heavy injury)
 - negation
 - actionType
(injury or death)
 - participantType
(man, woman, driver, etc.)
 - participantQuantity

Manually created rules

Design of extraction rules – iterative process



- 1 **Frequency analysis** → representative key-words.
- 2 Investigating of matching trees → **tuning** of tree query.
- 3 **Complexity** of the query \cong complexity of extracted data.

1 Introduction

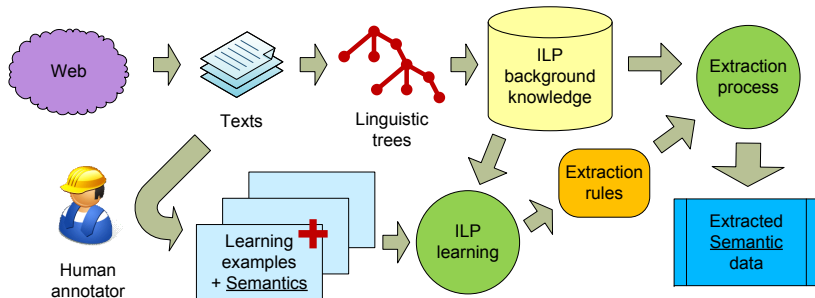
- Our Information Extraction System
- Linguistics we have used
- Domain of fire-department articles

2 Our Information Extraction Method

- Manually created rules
- Learning of rules
- Evaluation

3 Conclusion

Integration of ILP in our extraction process



- Transformation of trees to **logic representation**.
- Today: just **first promising experiments**.

Logic representation of linguistic trees



Zpravodajství

ČZS Jihomoravského kraje

Zprávy z 15.05.2007

V trabantu zemřeli dva lidé

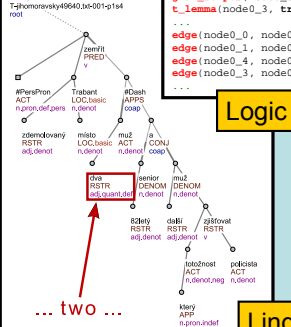
K tragické nehodě dnes dopoledne hasiči vyjžděli na silnici z obce Čoska do Kuliší na Brněnsku.

Nehoda byla opančována zprávkou zprávkou v 13.15 hodin. Na místě zasahovala jednotka profesionálních hasičů ze stanice Hřbitovní. Jednalo se o černý sáňku trabant Karosa s vozidlem Trabant. Před dostupných informací trabant jedoucí ve zřímě do Kuliší. Přemě vylze do průhledu, kde narážel do linkového autobusu dopravce společnosti ze Zlína nad Sazavou. Ve zdemolovaném trabantu nalezli zemřeli dva muži – řidič a sedící v zadní části. Jednalo se o dva muže, jejichž totožnost zatím nezjistili.

Hasiči ušli na vozidlo protipožární opatření a po vyšetření zdemolovaného trabantu dopravní policie vrak trabantu zakázala. Po vyšetření trabantu dopravní policie vrak trabantu zakázala. Po vyšetření trabantu dopravní policie vrak trabantu zakázala.

Source web page

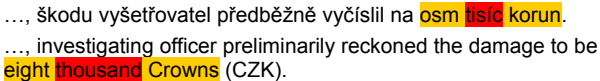
```
tree_root(node0_0). node(node0_0).
id(node0_0, t_jihomoravsky49640_txt_001_pls4).
***** node0_1 *****
node(node0_1).
functor(node0_1, pred).
gram_sempos(node0_1, v).
t_lemma(node0_1, zemrit).
***** node0_2 *****
node(node0_2).
functor(node0_2, act).
gram_sempos(node0_2, n_pron_def_pers).
t_lemma(node0_2, x_perspron).
***** node0_3 *****
node(node0_3). id(node0_3, zemrit).
functor(node0_3, loc).
gram_sempos(node0_3, n_denot).
t_lemma(node0_3, trabant).
...
edge(node0_0, node0_1). edge(node0_1, node0_2).
edge(node0_1, node0_3). edge(node0_3, node0_4).
edge(node0_4, node0_5). edge(node0_3, node0_6).
edge(node0_3, node0_7). edge(node0_3, node0_8).
```



... two ...

Logic representation

Linguistic trees



Examples of learned rules, Czech words are translated.

Example

[Rule 1] [Pos cover = 14 Neg cover = 0]

```
damage_root(A) :- lex_rf(B,A), has_sempos(B,'n.quant.def'),  
    tDependency(C,B), tDependency(C,D),  
    has_t_lemma(D,'investigator').
```

[Rule 2] [Pos cover = 13 Neg cover = 0]

```
damage_root(A) :- lex_rf(B,A), has_functor(B,'TOWH'),  
    tDependency(C,B), tDependency(C,D), has_t_lemma(D,'damage').
```

[Rule 1] [Pos cover = 7 Neg cover = 0]

```
injuries(A) :- lex_rf(B,A), has_functor(B,'PAT'),  
    has_gender(B,anim), tDependency(B,C), has_t_lemma(C,'injured').
```

[Rule 8] [Pos cover = 6 Neg cover = 0]

```
injuries(A) :- lex_rf(B,A), has_gender(B,anim), tDependency(C,B),  
    has_t_lemma(C,'injure'), has_negation(C,neg0).
```


1 Introduction

- Our Information Extraction System
- Linguistics we have used
- Domain of fire-department articles

2 Our Information Extraction Method

- Manually created rules
- Learning of rules
- Evaluation

3 Conclusion

Evaluation results

task/method	matching	missing	excess	overlap	prec.%	recall%	F1.0%
damage/ILP	14	0	7	6	51.85	70.00	59.57
damage/ILP – lenient measures					74.07	100.00	85.11
dam./ILP-roots	16	4	2	0	88.89	80.00	84.21
damage/Paum	20	0	6	0	76.92	100.00	86.96
injuries/ILP	15	18	11	0	57.69	45.45	50.85
injuries/Paum	25	8	54	0	31.65	75.76	44.64
inj./Paum-afun	24	9	38	0	38.71	72.73	50.53

- 10-fold cross validation
- Two tasks: ‘damage’ and ‘injuries’
- Root/subtree preprocessing/postprocessing used for ‘damage’ task

1 Introduction

- Our Information Extraction System
- Linguistics we have used
- Domain of fire-department articles

2 Our Information Extraction Method

- Manually created rules
- Learning of rules
- Evaluation

3 Conclusion

Summary

- Proposed a system for extraction of semantic information
- Based on linguistic tools for automatic text annotation
- Extraction rules adopted from **Netgraph** application.
- ILP used for learning rules.
- All methods integrated inside **GATE**³.
- Our future research will concentrate on:
 - **Learning** of extraction rules.
 - Extension of the method with WordNet technology.
 - Adaptation of this method on **other languages**.
 - **Evaluation** of the method.

³<http://gate.ac.uk/>